PROGRAMA FORMATIVO EJECUTIVO • 15 HORAS

Analítica Avanzada e Inteligencia Cognitiva

Programa Formativo Técnico y Estratégico para la Toma de Decisiones Basada en Datos

Temario Oficial 15H

6 Módulos exhaustivos de fundamentos, modelado predictivo, NLP y visualización.

5 Laboratorios Hands-on

Prácticas reales en Python con scikit-learn, XGBoost, Transformers y Streamlit.

Enfoque Ejecutivo & Técnico

Arquitecturas de datos Lakehouse, pipelines de MLOps y casos de negocio ROI-driven.

Documentación del Docente y Guía de Laboratorios • Formato Panorámico 16:9 • Español Técnico

MÓDULO 0 • ENCUADRE PEDAGÓGICO

Objetivos Oficiales y Competencias a Desarrollar

Desarrollo de capacidades avanzadas para extraer valor estratégico de grandes volúmenes de datos

PILAR 1 • PREDICTIVO

Modelado Predictivo & ML

Diseño, entrenamiento y validación de algoritmos supervisados y no supervisados.

- Ingeniería de variables y preprocesamiento riguroso.
- Algoritmos de regresión y ensamble (XGBoost / LightGBM).
- Segmentación no supervisada (K-Means / PCA).
- Validación cruzada y métricas orientadas al negocio.

PILAR 2 • COGNITIVO

Inteligencia Cognitiva & NLP

Extracción de conocimiento semántico a partir de lenguaje natural y fuentes complejas.

- Pipelines de preprocesamiento y tokenización moderna.
- Representaciones densas (Embeddings & Transformers).
- Análisis de sentimiento y Voice of the Customer (VoC).
- Integración de APIs cognitivas y arquitecturas RAG.

PILAR 3 • VISUALIZACIÓN

Visualización & Storytelling

Traducción de hallazgos analíticos complejos en paneles de toma de decisiones.

- Principios de percepción visual y gramática de gráficos.
- Arquitectura de dashboards analíticos interactivos.
- Presentación transparente de incertidumbre y riesgo.
- Diseño de interfaces en Streamlit y Power BI.

COMPROMISO FORMATIVO: DEL CONCEPTO AL PROYECTO OPERATIVO

Al finalizar las 15 horas, cada participante no solo dominará el corpus teórico del temario oficial, sino que habrá construido un repositorio de código funcional con 5 laboratorios prácticos y un proyecto transversal integrador listo para su adaptación en entornos profesionales.

Estructura Modular del Programa y Cronograma (15 Horas)

Distribución equilibrada entre fundamentos conceptuales, arquitecturas y laboratorios de código

Módulo	Denominación Temática	Enfoque Técnico	Laboratorio Práctico Incluido	Duración
Módulo 1	Introducción a la Analítica Avanzada	Madurez analítica, CRISP-DM, Lakehouse	Lab 1: Diagnóstico y Calidad de Datos (EDA)	2.5 h
Módulo 2	Fundamentos de Inteligencia Cognitiva	Sistemas cognitivos, APIs, Embeddings, RAG	Lab 2: Extracción Semántica con APIs/LLM	2.5 h
Módulo 3	Modelos Predictivos y Machine Learning	Supervisado/No supervisado, XGBoost, CrossVal	Lab 3: Modelo Predictivo de Churn con SHAP	3.5 h
Módulo 4	Análisis de Sentimientos y NLP	Preprocesamiento, Transformers, VoC	Lab 4: Pipeline de Sentimiento con Hugging Face	2.5 h
Módulo 5	Visualización de Datos Avanzada	Gestalt, Dashboards ejecutivos, Streamlit	Lab 5: Construcción de Dashboard Interactivo	2.0 h
Módulo 6	Casos Prácticos, MLOps y Proyecto	Arquitectura E2E, Drift, XAI, Retención 360°	Proyecto Final Integrador Transversal	1.5 h

MÓDULO 1 • 2.5 HORAS LECTIVAS

Introducción a la Analítica Avanzada

Conceptos Clave, Continuo de Madurez y Ciclo de Vida de los Proyectos de Datos

CONTENIDOS TÉCNICOS

- De los datos a la decisión: el continuo de madurez analítica.
- Diferencias entre analítica descriptiva, predictiva y prescriptiva.
- El ciclo metodológico de proyectos de datos: CRISP-DM y TDSP.
- Arquitecturas modernas de datos: Lakehouse, Delta y Feature Stores.

LABORATORIO PRÁCTICO & RESULTADO

- **Práctica: Lab 1 - Diagnóstico y Auditoría de Calidad de Datos**
- Objetivo: Profilado estadístico, detección de anomalías y preparación para ML.
- Entregable: Jupyter Notebook con informe reproducible y dataset curado.

El Continuo de Madurez Analítica (Gartner Framework)

Evolución desde la retrospectiva histórica hasta la toma de decisiones autónoma y optimizada

01 • DESCRIPTIVA

¿Qué ha ocurrido?

- **Visión retrospectiva**
- Técnicas: BI clásico, dashboards, KPIs históricos, agregaciones SQL.
- Resultado: Informes y reportes de estado.

02 • DIAGNÓSTICA

¿Por qué ocurrió?

- **Causalidad y patrones**
- Técnicas: Drill-down, minería de datos, correlaciones, análisis de raíz.
- Resultado: Identificación de factores críticos.

03 • PREDICTIVA

¿Qué ocurrirá?

- **Estimación probabilística**
- Técnicas: Machine Learning, series temporales, modelos de clasificación.
- Resultado: Scores de probabilidad y alertas.

04 • PRESCRIPTIVA

¿Qué debemos hacer?

- **Decisión y optimización**
- Técnicas: Optimización matemática, simulación, motores de reglas dinámicos.
- Resultado: Acción automatizada óptima.

TRANSICIÓN CLAVE: DE LA INFORMACIÓN RETROSPECTIVA A LA ACCIÓN AUTÓNOMA

A medida que una organización avanza hacia la derecha del espectro, el valor empresarial se multiplica exponencialmente. Sin embargo, también aumentan los requisitos de calidad de datos en tiempo real, gobernanza de modelos y tolerancia al riesgo algorítmico.

Matriz Comparativa de Enfoques Analíticos

Diferencias técnicas, metodológicas y de impacto empresarial en los 4 niveles de madurez

Nivel Analítico	Horizonte	Herramientas Clave	Caso Empresarial (Retail)	Impacto en el Negocio
Descriptiva	Pasado (T-n)	SQL, Power BI, Excel, Dashboards OLAP	Informe de ventas por tienda y SKU en el último trimestre.	Visibilidad retrospectiva de la salud del negocio.
Diagnóstica	Pasado reciente	Python (pandas, scipy), Minería causal, Clustering	Detección de por qué cayó la venta en tiendas del norte (roturas de stock).	Comprensión de causas raíz y anomalías operativas.
Predictiva	Futuro probable (T+1)	Scikit-learn, XGBoost, Prophet, Redes Neuronales	Predicción de la demanda de cada producto para los próximos 14 días.	Reducción de inventario ocioso y roturas de stock.
Prescriptiva	Futuro accionable	Optimización matemática (Gurobi, PuLP), Heurísticas	Plan automatizado de reabastecimiento y fijación dinámica de precios.	Maximización del margen bruto y automatización operativa.

Ciclo de Vida de Proyectos de Datos: De CRISP-DM a TDSP

El proceso iterativo estándar de la industria para garantizar el éxito y la gobernanza de modelos

FASE 01

Comprensión del Negocio

Definir el problema en términos de negocio. Fijar KPIs, restricciones legales, criterios de éxito financiero y diseño del caso de uso.

FASE 02

Comprensión de los Datos

Recolectar datos brutos, identificar problemas de calidad, balanceo de clases, dispersión y relaciones iniciales mediante EDA.

FASE 03

Preparación de los Datos

El 80% del esfuerzo: limpieza, imputación de nulos, ingeniería de características (features), escalado y división train/validation/test.

FASE 04

Modelado Analítico

Seleccionar técnicas algorítmicas, calibrar hiperparámetros, ensamblar modelos y aplicar validación cruzada estratificada.

FASE 05

Evaluación y Validación

Verificar si el modelo satisface los criterios de negocio definidos en la Fase 1. Análisis de costes, sesgos y explicabilidad.

FASE 06

Despliegue y MLOps

Pase a producción: APIs de inferencia en tiempo real o batch, monitorización continua de drift y reentrenamiento automatizado.

Arquitectura Moderna de Datos: El Paradigma Lakehouse

La convergencia de la flexibilidad del Data Lake con el gobierno ACID del Data Warehouse

BRONZE • INGESTA RAW

Capa Bronce (Cruda)

Aterrizaje directo de datos sin transformar desde múltiples fuentes heterogéneas.

- Fuentes: ERP, CRM, IoT, logs, APIs web.
- Formatos: JSON, Parquet, CSV, audio, imágenes.
- Patrón: Append-only con trazabilidad completa.
- Objetivo: Preservar la verdad histórica del dato.

SILVER • CURADA Y VALIDADA

Capa Plata (Estructurada)

Datos limpios, tipados, deduplicados y transformados para análisis transversal.

- Validación de esquemas y contratos de datos.
- Normalización y enriquecimiento de entidades.
- Soporte transaccional ACID (Delta / Iceberg).
- Base para analítica exploratoria y data science.

GOLD • CONSUMO DE NEGOCIO

Capa Oro (Especializada)

Vistas de negocio, modelos dimensionales y tablas para modelos predictivos.

- Esquemas en estrella para reporting y BI.
- Feature Store corporativo (variables para ML).
- Métricas estandarizadas y gobernadas.
- Mínima latencia de consulta y alta concurrencia.

EL ROL DEL FEATURE STORE EN LA ARQUITECTURA PREDICTIVA

El Feature Store resuelve la divergencia entre entrenamiento y servicio (Training-Serving Skew). Almacena variables precomputadas (ej. "gasto medio del cliente en los últimos 30 días") en dos almacenes sincronizados: Offline (Parquet/Delta para entrenamiento masivo) y Online (Redis/DynamoDB para inferencia en tiempo real en milisegundos).

MÓDULO 1 • LABORATORIO PRÁCTICO

Laboratorio 1: Diagnóstico y Auditoría de Datos Empresariales

Auditoría estadística rigurosa, detección de multicolinealidad y preparación de un dataset comercial

FICHA TÉCNICA DEL LABORATORIO

Objetivos y Metodología

Diagnosticar la salud de un dataset empresarial antes de aplicar cualquier modelo predictivo.

- **Dataset:**
- 50.000 clientes con historial transaccional y métricas de uso.
- **Herramientas:**
- Python 3.10+, pandas, ydata-profiling, seaborn, statsmodels.
- **Tiempo Estimado:**
- 45 minutos (30 min trabajo individual + 15 min puesta en común).
- **Competencia Clave:**
- Capacidad crítica para no fiarse de datos brutos sin auditar.

CHECKLIST DE TAREAS A COMPLETAR

Entregables del Ejercicio

Los alumnos deben ejecutar en su entorno las siguientes fases guiadas:

- 1. Generar e interpretar el reporte de perfilado HTML.
- 2. Clasificar el patrón de nulos y aplicar imputación adecuada.
- 3. Detectar variables con VIF > 10 y tratar la multicolinealidad.
- 4. Aislar outliers con Isolation Forest (contamination=0.03).
- 5. Exportar el dataset procesado a formato Parquet comprimido.
- 6. Redactar el resumen de hallazgos para el comité de datos.

MÓDULO 2 • 2.5 HORAS LECTIVAS

Fundamentos de la Inteligencia Cognitiva

Sistemas Capaces de Percibir, Comprender el Contexto, Razonar e Interactuar

CONTENIDOS TÉCNICOS

- Definición y pilares: comprensión, razonamiento, aprendizaje e interacción.
- Evolución tecnológica: de sistemas expertos y ML a modelos fundacionales.
- El catálogo de APIs cognitivas: visión, lenguaje, voz y decisión.
- Arquitecturas empresariales de RAG (Retrieval-Augmented Generation) y bases vectoriales.

LABORATORIO PRÁCTICO & RESULTADO

- **Práctica: Lab 2 - Extracción y Enriquecimiento Cognitivo con APIs/LLM**
- Objetivo: Procesamiento de documentos no estructurados mediante vectorización semántica.
- Entregable: Pipeline en Python con ChromaDB y recuperación contextual RAG.

¿Qué es la Inteligencia Cognitiva? Los 4 Pilares Fundamentales

Capacidades bio-inspiradas para procesar información no estructurada a escala masiva

PILAR 1 • PERCEPCIÓN

Comprensión Multimodal (Understand)

Capacidad de interpretar datos no estructurados complejos.

- Extracción semántica de texto, audio, señales y vídeo.
- Reconocimiento de intenciones, entidades y jerarquías.
- Superación de la ambigüedad lingüística y sintáctica.

PILAR 2 • LÓGICA

Razonamiento e Inferencia (Reason)

Capacidad de generar hipótesis y deducciones probabilísticas.

- Inferencia sobre grafos de conocimiento y bases vectoriales.
- Ponderación de evidencias frente a información incompleta.
- Trazabilidad lógica y justificación del camino de razonamiento.

PILAR 3 • ADAPTACIÓN

Aprendizaje Continuo (Learn)

Evolución dinámica del conocimiento del sistema.

- Mejora iterativa con nuevos datos transaccionales y de uso.
- Retroalimentación humana en el bucle (RLHF / Human-in-the-loop).
- Adaptación a cambios de dominio y vocabulario corporativo.

PILAR 4 • EXPERIENCIA

Interacción en Lenguaje Natural (Interact)

Diálogo fluido, empático y contextual con personas y sistemas.

- Interfaces conversacionales avanzadas (chatbots contextuales).
- Generación de lenguaje natural con control de tono y estilo.
- Colaboración transparente hombre-máquina (Co-pilots).

Evolución Tecnológica: Del Código Basado en Reglas a los LLMs

La transformación arquitectónica que habilitó el procesamiento del lenguaje y la percepción

ERA 1 • 1980-1995

Sistemas Expertos

- **Motor: Reglas Simbólicas**
- Datos: Bases de reglas Si/Entonces.
- Ventaja: Totalmente predecibles e interpretables.
- Límite: Frágiles ante excepciones; nula capacidad de aprendizaje.

ERA 2 • 2000-2012

ML Estadístico

- **Motor: Scikit-learn, SVM, RF**
- Datos: Datos estructurados tabulares.
- Ventaja: Capacidad predictiva rigurosa sobre métricas numéricas.
- Límite: Requiere costoso feature engineering manual por expertos.

ERA 3 • 2012-2017

Deep Learning

- **Motor: CNNs, LSTMs, GRUs**
- Datos: Imágenes, audio, secuencias.
- Ventaja: Aprendizaje automático de representaciones jerárquicas.
- Límite: Alto consumo de GPU; cuello de botella secuencial en texto.

ERA 4 • 2017-HOY

Modelos Fundacionales

- **Motor: Transformers, LLMs**
- Datos: Texto masivo, código, multimodal.
- Ventaja: Razonamiento contextual, zero-shot learning y multimodalidad.
- Límite: Riesgo de alucinaciones; requiere técnicas de guardrails y RAG.

EL MECANISMO DE AUTOATENCIÓN (SELF-ATTENTION)

A diferencia de las arquitecturas secuenciales que leían palabra por palabra olvidando el inicio de párrafos largos, el mecanismo de atención calcula la afinidad semántica de cada palabra con todas las demás de forma simultánea mediante matrices de Query, Key y Value (Attention(Q,K,V) = softmax((Q * K^T) / sqrt(d_k)) * V).

El Catálogo de Servicios y APIs Cognitivas Empresariales

Capacidades cognitivas preentrenadas listas para consumir mediante interfaces REST y SDKs

VISIÓN ARTIFICIAL

Percepción Visual

Análisis de imágenes y vídeo en streaming.

- OCR avanzado de documentos (facturas, DNI).
- Detección y clasificación de objetos en tiempo real.
- Inspección visual de calidad en manufactura.
- Moderación de contenido gráfico sensible.
- **Proveedores: Azure Computer Vision, Google Cloud Vision, AWS Rekognition.**

LENGUAJE Y TEXTO

Comprensión Textual

Extracción de valor de texto libre corporativo.

- Análisis de sentimiento y polaridad por aspectos.
- Extracción de entidades nombradas (NER).
- Resumen automático y detección de PII (datos personales).
- Traducción neuronal multilingüe en tiempo real.
- **Proveedores: Azure AI Language, Google Vertex Natural Language, AWS Comprehend.**

VOZ Y AUDIO

Procesamiento de Voz

Transformación bidireccional voz-texto.

- Speech-to-Text (STT) con transcripción fonética.
- Text-to-Speech (TTS) neuronal hiperrealista.
- Identificación biométrica de locutor en call centers.
- Detección de emociones en la modulación de voz.
- **Proveedores: Azure Speech Services, Google Cloud Speech, AWS Transcribe / Polly.**

BÚSQUEDA Y DECISIÓN

Búsqueda Semántica

Recuperación de conocimiento y toma de decisión.

- Búsqueda vectorial híbrida (semántica + léxica).
- Detección de anomalías en streaming temporal.
- Personalización y motores de recomendación.
- Sistemas de defensa contra fraude en transacciones.
- **Proveedores: Azure AI Search, Vertex AI Search, AWS Kendra / OpenSearch.**

Arquitectura Cognitiva Empresarial: RAG & Agentes Autónomos

Integración de modelos fundacionales con bases de conocimiento privadas mediante recuperación vectorial

PASO 1

Ingesta & Chunking

Extracción de texto desde fuentes dispersas (PDFs, ERP, repositorios).

- Particionamiento semántico.
- Gestión de solapamiento (overlap).
- Limpieza de metadatos.

PASO 2

Vectorización Densa

Conversión de texto a vectores densos mediante modelos de embeddings.

- Embeddings de 1536 dimensiones.
- Captura de afinidad conceptual.
- Almacenamiento en Vector DB.

PASO 3

Recuperación Híbrida

Búsqueda K-NN por similitud coseno combinada con búsqueda léxica BM25.

- Ranking por relevancia.
- Filtros de permisos de acceso.
- Re-ranking de resultados.

PASO 4

Generación Aumentada

Inyección de contexto en el LLM para generar una respuesta grounded.

- Cero alucinaciones corporativas.
- Cita de fuentes originales.
- Guardrails éticos y de seguridad.

MEJORES PRÁCTICAS EN RAG INDUSTRIAL: BÚSQUEDA HÍBRIDA Y GUARDRAILS

La búsqueda puramente vectorial falla al buscar códigos exactos o identificadores alfanuméricos (ej. "Contrato CTR-2024-99B"). Una solución industrial robusta implementa Búsqueda Híbrida (Hybrid Search), combinando la similitud semántica con algoritmos de coincidencia exacta (BM25) y una capa de Re-ranking (Cross-Encoders) antes de alimentar el contexto al modelo.

Laboratorio 2: Extracción Semántica y Enriquecimiento con APIs/LLM

Construcción de un pipeline en Python para vectorizar documentos y ejecutar consultas RAG

FICHA TÉCNICA DEL LABORATORIO

Objetivos y Tecnologías

Implementar un motor de búsqueda semántica y enriquecimiento cognitivo funcional.

- **Corpus de Datos:**
- 200 documentos de políticas corporativas y contratos.
- **Librerías Python:**
- ChromaDB, sentence-transformers, LangChain / LlamaIndex.
- **Modelo de Embeddings:**
- all-MiniLM-L6-v2 (384 dimensiones, rápido y local).
- **Tiempo Asignado:**
- 45 minutos (30 min desarrollo + 15 min debate).

PASO A PASO DE LA PRÁCTICA

Hitos de Construcción del Pipeline

Secuencia de implementación en el entorno de desarrollo:

- 1. Particionar los textos con solapamiento semántico de 50 tokens.
- 2. Calcular los vectores densos y almacenarlos en ChromaDB.
- 3. Enriquecer cada vector con metadatos clave para filtrado.
- 4. Ejecutar consultas semánticas y medir distancia coseno.
- 5. Evaluar la tasa de acierto frente a palabras clave tradicionales.
- 6. Exportar la función de inferencia lista para producción.

MÓDULO 3 • 3.5 HORAS LECTIVAS

Modelos Predictivos y Machine Learning

De la Teoría Estadística a los Algoritmos de Producción: Supervisado, No Supervisado y Validación

CONTENIDOS TÉCNICOS

- Taxonomía matemática y conceptual del Machine Learning.
- Algoritmos supervisados: modelos lineales, regularización, árboles y ensamblados (XGBoost).
- Algoritmos no supervisados: clustering (K-Means, DBSCAN) y reducción de dimensionalidad (PCA).
- Ingeniería de variables, prevención de data leakage y validación cruzada estratificada.
- Métricas de evaluación críticas y explicabilidad con valores SHAP.

LABORATORIO PRÁCTICO & RESULTADO

- **Práctica: Lab 3 - Modelo Predictivo de Churn con XGBoost y SHAP**
- Objetivo: Pipeline completo en scikit-learn con tuning bayesiano e interpretabilidad ejecutiva.
- Entregable: Modelo entrenado, matriz de confusión optimizada y análisis de impacto ROI.

Taxonomía del Machine Learning: Los 3 Grandes Paradigmas

Estructuración matemática según la naturaleza de la señal de entrenamiento disponible

PARADIGMA 1 • ETIQUETADO

Aprendizaje Supervisado

Entrenamiento con datos de entrada (X) y variable objetivo (y) conocida.

- **Problemas de Regresión:**
- Predicción de variables numéricas continuas (demanda, precios, LTV).
- **Problemas de Clasificación:**
- Asignación a categorías discretas (abandono sí/no, fraude, diagnóstico).
- **Algoritmos Representativos:**
- Regresión Logística, Random Forest, XGBoost, LightGBM, Redes MLP.
- **Reto Principal:**
- Coste y calidad del etiquetado; sobreajuste a datos históricos.

PARADIGMA 2 • ESTRUCTURA LATENTE

Aprendizaje No Supervisado

Descubrimiento de patrones, agrupaciones y geometrías ocultas en X sin etiquetas.

- **Técnicas de Clustering:**
- Agrupamiento por similitud (segmentación de clientes, perfiles de consumo).
- **Reducción de Dimensionalidad:**
- Compresión de variables preservando varianza o topología (PCA, t-SNE).
- **Detección de Anomalías:**
- Identificación de observaciones atípicas (Isolation Forest, One-Class SVM).
- **Reto Principal:**
- Validación matemática objetiva; no hay ground truth evidente.

PARADIGMA 3 • INTERACCIÓN Y CONTROL

Aprendizaje por Refuerzo

Optimización de secuencias de decisiones mediante recompensas y penalizaciones.

- **Agente y Entorno:**
- Bucle continuo de Estado (S) -> Acción (A) -> Recompensa (R).
- **Aplicaciones Empresariales:**
- Fijación dinámica de precios, optimización de inventario, trading.
- **Algoritmos Representativos:**
- Q-Learning, Deep Q-Networks (DQN), PPO, Actor-Critic.
- **Reto Principal:**
- Necesidad de simuladores precisos; lenta convergencia en entornos reales.

Algoritmos Supervisados: De Modelos Lineales a Gradient Boosting

Mapeo de técnicas, interpretabilidad vs capacidad predictiva y fundamentos matemáticos

MODELOS LINEALES

Regresión Lineal, Logística & Regularización

Relación aditiva y = beta_0 + sum(beta_j * X_j). Alta interpretabilidad.

- Ridge (L2): Penalización cuadrática para mitigar varianza.
- Lasso (L1): Fuerza coeficientes a cero (selección de variables).
- ElasticNet: Combinación convexa de L1 y L2 ante multicolinealidad.

BAGGING / PARALELO

Random Forest (Bosques Aleatorios)

Ensamble de árboles independientes entrenados en paralelo sobre submuestras.

- Bootstrap Sampling: Selección aleatoria de filas con reemplazo en cada árbol.
- Feature Bagging: Subconjunto aleatorio de variables en cada división de nodo.
- Robusto frente a ruido y outliers; reduce la varianza sin incrementar el sesgo.

BOOSTING / SECUENCIAL

XGBoost & LightGBM (Gradient Boosting)

Ensamble secuencial donde cada árbol corrige los errores residuales del anterior.

- Optimización de segundo orden (cálculo analítico del gradiente y hessiano).
- Gestión automática de valores nulos y particionamiento en paralelo.
- Estado del arte indiscutible en rendimiento para datos tabulares empresariales.

NO LINEALES COMPLEJOS

SVM & Redes Neuronales (MLP)

Fronteras de decisión complejas en espacios multivariantes.

- SVM con Kernel RBF: Proyección a alta dimensión para separación.
- Perceptrón Multicapa (MLP): Capas ocultas con activación no lineal.
- Uso preferente: Datos no estructurados o geometrías intrincadas.

Aprendizaje No Supervisado: Clustering y Reducción Dimensional

Segmentación de observaciones y compresión de espacios multivariantes sin etiquetas

TÉCNICAS DE CLUSTERING

Algoritmos de Agrupamiento

Segmentación de observaciones en grupos homogéneos internamente y heterogéneos entre sí.

- **K-Means:**
- Partición por centroides. Rápido y escalable. Requiere fijar K (Elbow method / Silhouette). Sensible a la escala.
- **DBSCAN (Density-Based):**
- Agrupa por densidad espacial (radio epsilon y MinPts). Descubre geometrías no convexas y aisla ruido.
- **Clustering Jerárquico:**
- Construcción de dendrogramas aglomerativos. Ideal cuando existe taxonomía jerárquica en el negocio.
- **Métricas de Evaluación:**
- Coeficiente Silhouette (-1 a +1), Índice Davies-Bouldin, Calinski-Harabasz.

REDUCCIÓN DIMENSIONAL

Compresión y Visualización de Espacios

Transformación de datasets con decenas de variables en representaciones compactas.

- **PCA (Componentes Principales):**
- Transformación lineal que maximiza la varianza retenida. Elimina la multicolinealidad entre variables.
- **Scree Plot & Varianza Explicada:**
- Selección del número de componentes que retengan al menos el 80-90% de la información original.
- **t-SNE & UMAP (No Lineales):**
- Preservación de la estructura topológica local. Estándar para visualizar clusters complejos en 2D/3D.
- **Aplicación Práctica:**
- Comprimir 50 variables a 5 componentes antes de alimentar un modelo supervisado para evitar el sobreajuste.

Ingeniería de Características y Prevención de Data Leakage

El factor más determinante en el rendimiento de los modelos en producción

PASO 1

Imputación de Nulos

Tratamiento riguroso de valores ausentes.

- Mediana / Moda por grupo.
- KNN Imputer para relaciones multivariantes.
- Indicador binario de missing.

PASO 2

Codificación Categórica

Traducción de texto a señales numéricas.

- One-Hot Encoding (baja cardinalidad).
- Target Encoding con regularización.
- Weight of Evidence (WoE) en scoring.

PASO 3

Escalado & Transformación

Homogeneización de magnitudes.

- StandardScaler (z-score).
- RobustScaler (resistente a outliers).
- Transformación Box-Cox / Log.

PASO 4

Variables de Negocio

Construcción de métricas sintéticas.

- Ratios y proporciones temporales.
- Tendencias y diferencias (T-1 vs T-30).
- Métricas RFM (Recencia, Frecuencia, Valor).

REGLA DE ORO DE PRODUCCIÓN: PREVENCIÓN ABSOLUTA DE DATA LEAKAGE

Cualquier cálculo estadístico (medias de imputación, desviaciones de escalado, vocabularios de texto o frecuencias de categorías) DEBE calcularse exclusivamente sobre el conjunto de entrenamiento (Train) y aplicarse de forma ciega sobre Validación y Test usando pipelines reproducibles (ej. scikit-learn Pipeline / ColumnTransformer). Si calculas la media antes del split, tu modelo parecerá perfecto en el laboratorio pero fracasará estrepitosamente en producción.

Evaluación de Clasificación: Más Allá de la Trampa del Accuracy

Métricas robustas para clases desbalanceadas y alineación con la matriz de costes de negocio

TP / (TP+FP)

PRECISIÓN

Minimiza Falsos Positivos. Clave cuando alertar erróneamente tiene un alto coste operativo.

TP / (TP+FN)

RECALL / SENSIBILIDAD

Minimiza Falsos Negativos. Crítico cuando dejar escapar un caso real es catastrófico.

2·(P·R)/(P+R)

F1-SCORE (ARMÓNICO)

Balance óptimo entre precisión y cobertura en escenarios con clases moderadamente desbalanceadas.

ROC & PR-AUC

ÁREA BAJO LA CURVA

Mide la capacidad de ranking del modelo independientemente del umbral de corte seleccionado.

Matriz de Confusión	Predicción Negativa (0)	Predicción Positiva (1)	Impacto en el Negocio (Caso Churn)
Real Negativo (0 - No Churn)	Verdadero Negativo (TN) Cliente fiel no tocado	Falso Positivo (FP - Error Tipo I) Oferta enviada a cliente fiel	Coste de la campaña de retención innecesaria (ej. 15€).
Real Positivo (1 - Churn)	Falso Negativo (FN - Error Tipo II) Cliente que se marcha sin aviso	Verdadero Positivo (TP) Cliente retenido proactivamente	Pérdida irreversible del valor de vida del cliente (LTV = 600€).

Validación Cruzada y el Dilema Sesgo-Varianza (Bias-Variance)

Cómo garantizar que el modelo generalice ante datos futuros nunca vistos

DILEMA SESGO-VARIANZA

Subajuste vs Sobreajuste

El equilibrio entre la simplicidad del modelo y su capacidad de captura de patrones.

- **Alto Sesgo (Underfitting):**
- El modelo simplifica en exceso la realidad. Error elevado tanto en el conjunto de entrenamiento como en validación.
- **Alta Varianza (Overfitting):**
- El modelo memoriza el ruido del conjunto de entrenamiento. Error mínimo en train, pero fracaso en validación/test.
- **Técnicas de Mitigación:**
- Aumentar datos de entrenamiento, regularización L1/L2, podado de árboles (max_depth), dropout en redes.
- **Objetivo de Producción:**
- Maximizar la capacidad de generalización sobre observaciones completamente nuevas.

ESTRATEGIAS DE VALIDACIÓN

Estrategias de Partición de Datos

Protocolos de validación estadística para estimar el error de forma insesgada.

- **Partición Train / Val / Test (60/20/20):**
- Train para ajustar parámetros, Val para calibrar hiperparámetros y Test como cofre sellado final.
- **Stratified K-Fold Cross-Validation:**
- Partición en K bloques (típicamente K=5 o 10) preservando la distribución de clases en cada pliegue.
- **TimeSeriesSplit (Validación Temporal):**
- Ventana expansiva o deslizante temporal. Prohibido mezclar observaciones futuras con pasadas.
- **Nested Cross-Validation:**
- Validación anidada para optimización de hiperparámetros sin sesgo de selección.

MÓDULO 3 • LABORATORIO PRÁCTICO

Laboratorio 3: Predicción de Churn con XGBoost y Valores SHAP

Construcción, optimización con Optuna e interpretabilidad con XAI para comités directivos

FICHA TÉCNICA DEL LABORATORIO

Especificaciones del Modelo

Desarrollo de un pipeline predictivo completo y explicable orientado al ROI empresarial.

- **Caso de Negocio:**
- Predicción del abandono mensual en cartera de clientes corporativos.
- **Algoritmo Principal:**
- XGBoost (Extreme Gradient Boosting) con calibración de probabilidad.
- **Métrica Primaria de Optimización:**
- PR-AUC (Área bajo la curva Precision-Recall) y Coste Total.
- **Librerías Clave:**
- scikit-learn, xgboost, optuna, shap, matplotlib.

HITOS DE IMPLEMENTACIÓN

Flujo de Ejecución en el Notebook

Etapas que cada alumno debe completar y verificar:

- 1. Partición estratificada 80/20 con StratifiedShuffleSplit.
- 2. Construcción de Pipeline con preprocesadores herméticos.
- 3. Optimización bayesiana de hiperparámetros con Optuna (30 trials).
- 4. Simulación de umbrales de corte (Threshold Tuning) por coste financiero.
- 5. Extracción de valores SHAP mediante TreeExplainer.
- 6. Generación de informe ejecutivo con recomendaciones de retención.

MÓDULO 4 • 2.5 HORAS LECTIVAS

Análisis de Sentimientos y NLP

Desbloqueando el Valor del Texto: De la Sintaxis Lingüística a la Semántica Contextual de los Transformers

CONTENIDO TÉCNICO

- El pipeline de preprocesamiento en NLP: tokenización por subpalabras y normalización.
- Representaciones vectoriales del lenguaje: BoW, TF-IDF, Word2Vec y Embeddings contextuales.
- Técnicas de análisis de sentimiento: léxicos, clasificadores supervisados, Transformers y LLMs.
- Aspect-Based Sentiment Analysis (ABSA) y minería de opiniones en Voice of Customer (VoC).

LABORATORIO PRÁCTICO & RESULTADO

- **Práctica: Lab 4 - Pipeline de Sentimiento y Minería de Opiniones en Español**
- Objetivo: Comparativa entre modelos baseline (TF-IDF) y Transformers preentrenados.
- Entregable: Script con Hugging Face, matriz de confusión de polaridad y clustering de tópicos.

El Pipeline de Preprocesamiento en Procesamiento del Lenguaje Natural

De cadenas de caracteres crudas a secuencias de tokens estructuradas

PASO 1

Limpieza & Normalización

Homogeneización de cadenas de texto.

- Eliminación de HTML, URLs y caracteres especiales.
- Mapeo semántico de emojis y hashtags.
- Corrección ortográfica básica y minúsculas.

PASO 2

Tokenización Avanzada

Segmentación en unidades léxicas procesables.

- Tokenización por palabras y puntuación.
- Tokenización por subpalabras (BPE, WordPiece).
- Manejo absoluto de vocabulario desconocido (OOV).

PASO 3

Reducción Morfológica

Unificación de variantes flexivas.

- Stemming: corte heurístico de afijos.
- Lematización: reducción al lema formal (POS).
- Filtro selectivo de Stopwords según el modelo.

PASO 4

Extracción de Secuencias

Captura de contexto local y n-gramas.

- Unigramas, Bigramas y Trigramas.
- Preservación de negaciones ("no_bueno").
- Alineación de longitud (Padding & Truncation).

EL DILEMA DE LAS STOPWORDS: ¿ELIMINAR O CONSERVAR?

En pipelines tradicionales basados en Bag-of-Words o TF-IDF, eliminar las stopwords es imperativo para evitar que términos ultra-frecuentes como "de", "que" o "en" dominen el vocabulario. Sin embargo, en modelos basados en Transformers (BERT, RoBERTa, GPT), NUNCA deben eliminarse: la atención bidireccional utiliza precisamente los artículos, preposiciones y signos de puntuación para inferir relaciones sintácticas y de negación ("no es bueno" vs "es bueno").

Representación Vectorial: De la Bolsa de Palabras a Embeddings

La transición de vectores dispersos sin semántica a espacios densos de atención contextual

GENERACIÓN 1 • VECTORES DISPERSOS

Bag-of-Words & TF-IDF

Matrices de recuento de frecuencia ponderada por especificidad en el corpus.

- **Mecánica:**
- Vocabulario de N palabras. Matriz dispersa de ceros con recuentos o pesos TF-IDF.
- **Fórmula Clave:**
- TF(t,d) * log(N / DF(t)). Penaliza términos ubicuos en la colección.
- **Ventajas:**
- Extremadamente rápido de calcular, interpretable y ligero.
- **Limitación Fatal:**
- Ortogonalidad estricta: ignora sinónimos y destruye el orden sintáctico.

GENERACIÓN 2 • ESPACIOS DENSOS

Word2Vec & GloVe

Vectores continuos de baja dimensión aprendidos por coocurrencia local.

- **Mecánica:**
- Arquitecturas Skip-gram y CBOW con Softmax jerárquico o Negative Sampling.
- **Geometría Semántica:**
- Palabras con significados afines se sitúan cerca en el espacio vectorial continuo.
- **Ventajas:**
- Captura relaciones analógicas (Francia:París :: España:Madrid).
- **Limitación Fatal:**
- Vectores estáticos: incapacidad de resolver polisemia y ambigüedad.

GENERACIÓN 3 • ATENCIÓN CONTEXTUAL

Transformers (BERT, RoBERTa)

Embeddings contextuales dinámicos generados mediante autoatención.

- **Mecánica:**
- Masked Language Modeling (MLM) bidireccional sobre corpus masivos.
- **Contexto Dinámico:**
- La representación del token muta según las palabras precedentes y posteriores.
- **Ventajas:**
- Resuelve la polisemia, el sarcasmo y relaciones complejas de largo alcance.
- **Requisito:**
- Mayor demanda computacional durante inferencia (optimizable con ONNX).

Técnicas de Análisis de Sentimientos: Del Léxico al Fine-Tuning

Comparativa metodológica para clasificar la polaridad y las emociones en opiniones de usuarios

MÉTODO 1 • REGLAS Y DICCIONARIOS

Léxicos (VADER / TextBlob)

Diccionarios predefinidos de palabras con valores de polaridad asociados.

- Sin coste de entrenamiento ni necesidad de datos etiquetados.
- Heurísticas para intensificadores ("extremadamente bueno").
- Inversión automática de polaridad ante negaciones gramaticales.
- Limitación: Nula adaptación a jergas corporativas o ironías complejas.

MÉTODO 2 • APRENDIZAJE SUPERVISADO

TF-IDF + Clasificadores

Entrenamiento de modelos lineales o ensamble sobre corpus etiquetado.

- Extracción de n-gramas relevantes para el negocio.
- Ajuste con Regresión Logística, Naive Bayes o SVM.
- Excelente relación entre precisión y coste computacional en CPU.
- Limitación: Requiere miles de ejemplos etiquetados de calidad.

MÉTODO 3 • TRANSFORMERS & LLMS

Transformers Finetuneados

Modelos de lenguaje profundos especializados en análisis de polaridad.

- Modelos preentrenados en español (BETO, pysentimiento, RoBERTa).
- Comprensión superior del contexto, sarcasmo y dobles sentidos.
- Capacidad de extracción granular de emociones (ira, alegría, sorpresa).
- Inferencia adaptable mediante Zero-Shot Prompting con LLMs.

EL VALOR ESTRATÉGICO DEL ASPECT-BASED SENTIMENT ANALYSIS (ABSA)

En el entorno empresarial, decir que un cliente está "descontento" es insuficiente. ABSA desacopla el texto en tuplas estructuradas de [Entidad, Aspecto, Polaridad]. Por ejemplo, en una reseña hotelera: [Habitación: +0.9 (Limpia y amplia)], [Ubicación: +0.8 (Céntrica)], [Recepción: -0.85 (Trato descortés y check-in lento)]. Esto permite a los departamentos operativos actuar de forma quirúrgica sobre el problema real.

Aplicaciones Empresariales de NLP: Voice of Customer y Marketing

Casos reales de explotación de texto no estructurado para maximizar retención y captación

CASO 1 • REPUTACIÓN SOCIAL

Monitorización de Marca en Streaming

Detección temprana de incendios reputacionales en redes.

- Ingesta de menciones sociales con alertas automáticas ante anomalías.
- Clustering de causas raíz para aislar el motivo del malestar.
- Reducción del tiempo de respuesta del gabinete de prensa a < 15 min.

CASO 2 • ATENCIÓN AL CLIENTE

Triaje y Enrutamiento Inteligente de Tickets

Clasificación automática por severidad y departamento.

- Asignación prioritaria a operadores senior de usuarios enfurecidos.
- Resumen extractivo automático del problema para agilizar la resolución.
- Ahorro del 40% en tiempos de gestión manual de buzones de soporte.

CASO 3 • I+D Y PRODUCTO

Inteligencia Competitiva de Producto

Benchmarking continuo mediante minería de opiniones.

- Extracción de funcionalidades más alabadas y criticadas de la competencia.
- Identificación de fallos de diseño y oportunidades de packaging.
- Priorización del roadmap de producto respaldada por datos de clientes.

CASO 4 • RETENCIÓN ACTIVA

Prevención de Bajas en Call Centers

Análisis continuo sobre transcripciones de llamadas.

- Detección de patrones de hostilidad o decepción durante la llamada.
- Despliegue dinámico de scripts de retención y bonos en pantalla del agente.
- Incremento del 22% en la tasa de rescate de clientes en riesgo inminente.

MÓDULO 4 • LABORATORIO PRÁCTICO

Laboratorio 4: Clasificación de Sentimiento y Minería de Tópicos

Implementación comparativa entre modelos estadísticos y Transformers en español

FICHA TÉCNICA DEL LABORATORIO

Objetivos y Tecnologías

Construir y comparar pipelines de clasificación de sentimiento y extracción temática.

- **Corpus:**
- 10.000 opiniones reales de clientes de e-commerce en español.
- **Stack Técnico:**
- Hugging Face Transformers, scikit-learn, BERTopic, pandas.
- **Modelos Evaluados:**
- TF-IDF + LogisticRegression vs RoBERTa preentrenado en español.
- **Tiempo Asignado:**
- 45 minutos (30 min código guiado + 15 min análisis de errores).

ENTREGABLES DEL LABORATORIO

Hitos Prácticos a Resolver

Tareas obligatorias en el cuaderno de trabajo:

- 1. Implementar la limpieza y extracción de bigramas en Python.
- 2. Entrenar y calibrar el clasificador lineal de referencia.
- 3. Ejecutar inferencia con el modelo Transformer en GPU/CPU.
- 4. Comparar matrices de confusión y analizar falsos positivos.
- 5. Extraer los 5 tópicos dominantes en comentarios negativos.
- 6. Exportar las predicciones consolidadas para el dashboard del Lab 5.

MÓDULO 5 • 2.0 HORAS LECTIVAS

Visualización de Datos Avanzada

Comunicar con Impacto: Principios de Percepción, Arquitectura de Dashboards y Storytelling con Datos

CONTENIDOS TEÓRICOS

- Fundamentos cognitivos de la visualización: atributos preatentivos y leyes de Gestalt.
- El ratio datos-tinta de Edward Tufte y selección rigurosa de tipos de gráficos.
- Ecosistema tecnológico: plataformas BI corporativas vs frameworks de Data Apps en Python.
- Anatomía y diseño de dashboards ejecutivos orientados a la toma de decisiones inmediata.

LABORATORIO PRÁCTICO & RESULTADO

- **Práctica: Lab 5 - Prototipado y Despliegue de un Dashboard Interactivo**
- Objetivo: Construcción de una aplicación web en Streamlit que integre predicciones y sentimiento.
- Entregable: Dashboard interactivo con filtros cruzados, tarjetas de KPI y visualización explicable.

Principios de Percepción Visual y Gramática de Gráficos

Cómo procesa el cerebro humano la información visual antes del razonamiento consciente

NEUROCIENCIA VISUAL

Atributos Preatentivos

Procesamiento cerebral subconsciente en menos de 200 milisegundos.

- **Jerarquía de Precisión:**
- 1. Posición en eje común > 2. Longitud > 3. Área > 4. Intensidad de color > 5. Ángulo.
- **Uso Funcional del Color:**
- Utilizar color únicamente para dirigir la atención o codificar estados (éxito, alerta).
- **Economía Visual:**
- No codificar más de dos atributos visuales simultáneamente en el mismo elemento.

PSICOLOGÍA GESTALT

Leyes de Agrupamiento Gestalt

Reglas de organización perceptual que estructuran la mente humana.

- **Ley de Proximidad:**
- Separar métricas no relacionadas mediante espacio en blanco y agrupar KPIs afines.
- **Ley de Cerramiento:**
- Contener bloques lógicos en tarjetas limpias con bordes o fondos suaves.
- **Ley de Continuidad:**
- Alinear visualmente filtros, títulos y ejes para guiar el flujo de lectura.

PRINCIPIO DE TUFTE

Maximización del Data-Ink Ratio

Eliminación radical de ruido y decoración superflua en gráficos.

- **Erradicar el "Chartjunk":**
- Prohibición total de gráficos 3D, degradados estridentes y sombras exageradas.
- **Atenuación de Cuadrículas:**
- Líneas de eje sutiles en gris claro o eliminadas si existen etiquetas directas de datos.
- **Etiquetado Directo:**
- Preferir etiquetas sobre las barras en lugar de leyendas lejanas que exijan desviar la vista.

Ecosistema Tecnológico: Plataformas BI vs Data Apps en Código

Criterios de selección arquitectónica entre herramientas de autoservicio y frameworks de desarrollo

Criterio de Evaluación	Plataformas de BI (Power BI / Tableau)	Data Apps en Código (Streamlit / Dash)
Audiencia Principal	Comités de dirección, analistas de negocio y mandos intermedios no técnicos.	Científicos de datos, equipos de producto, operaciones y usuarios especializados.
Integración de ML / IA	Limitada a scripts integrados o inferencias batch precalculadas en el data warehouse.	Nativa: ejecución en tiempo real de scikit-learn, Transformers, SHAP y llamadas a LLMs.
Gobernanza y RLS	Nativa empresarial (Azure AD / SSO, seguridad por fila gobernada centralmente).	Debe implementarse a nivel de software o delegarse en el gateway del API.
Curva de Desarrollo	Muy rápida para reportes estándar; compleja para interacciones fuera de catálogo.	Extremadamente rápida en Python puro (100% código, sin frontend HTML/CSS/JS).
Simulaciones What-If	Complejas mediante parámetros DAX o parámetros de simulación limitados.	Nativas y dinámicas: sliders que recalculan matrices y modelos en milisegundos.

MÓDULO 5 • DISEÑO DE INTERFACES

Anatomía y Arquitectura de un Dashboard Ejecutivo de Impacto

Estructuración visual en cuadrículas jerárquicas basada en patrones naturales de lectura

ZONA 1 • BARRA DE CONTROL Y FILTROS GLOBALES

Selector de Horizonte Temporal (Últimos 30d / YTD) • Filtro por Segmento de Cliente • Filtro Regional • Estado de Calidad de Datos

TASA DE ABANDONO

2.14% (Churn)

▲ +0.3% vs obj. (Alerta)

SENTIMIENTO MEDIO

+0.72 Polaridad

▲ +0.08 vs mes anterior

CLIENTES EN RIESGO

1.420 Cuentas

Score Churn > 0.70

VALOR EN RIESGO (ARR)

840.000 €

Objetivo de retención activa

ZONA 3A • TENDENCIA Y PROYECCIÓN ML

Evolución Histórica y Bandas de Confianza Predictivas

Gráfico de líneas con intervalo del 95% para los próximos 60 días.

- Línea continua: Datos reales consolidados.
- Línea discontinua con sombreado: Inferencia del modelo XGBoost.
- Marcadores de eventos: Puntos de inflexión por cambios de tarifa.

ZONA 3B • DETALLE ACCIONABLE

Top Cuentas Prioritarias

Tabla filtrable con llamada a la acción directa.

- ID de Cliente y Razón Social.
- Score de Riesgo y Factores SHAP.
- Botón "Asignar Acción a Gestor".

MÓDULO 5 • INTEGRACIÓN AVANZADA

Integración de Modelos Predictivos y Sentimiento en Paneles

Cómo presentar probabilidades complejas e inferencias de NLP de forma transparente y accionable

REGLA 1 • SEMÁNTICA

Probabilidad a Acción

Traducción de números estadísticos a categorías operativas inteligibles.

- Mapeo de probabilidades en cuartiles de riesgo (Bajo, Medio, Alto, Crítico).
- Formatos condicionales sobrios sin saturación de colores.
- Estimación del impacto económico directo asociado a la predicción.

REGLA 2 • EXPLICABILIDAD

XAI Embebida (SHAP)

Justificación transparente del motivo de cada inferencia algorítmica.

- Micro-gráficos de cascada al hacer clic sobre cualquier registro individual.
- Top 3 variables explicativas que justifican la alerta del modelo.
- Desmitificación de la "caja negra" ante el usuario de operaciones.

REGLA 3 • CONFIANZA

Gobernanza y Calidad

Panel de observabilidad y frescura del sistema predictivo.

- Indicador de frescura: fecha y hora de la última inferencia batch.
- Semáforo de Data Drift: alerta si los datos entrantes divergen de train.
- Canal de feedback directo: botón para que el usuario reporte falsos positivos.

EL BUCLE DE FEEDBACK DE USUARIO (HUMAN-IN-THE-LOOP)

Un dashboard avanzado no debe ser unidireccional. Incluir mecanismos interactivos para que el gestor de negocio valide o refute la predicción del modelo (ej. "¿Considera acertada esta alerta de abandono? Sí / No"). Estos registros se capturan de vuelta en la capa Silver del Lakehouse para auditar sesgos y servir de base en los ciclos de reentrenamiento.

MÓDULO 5 • LABORATORIO PRÁCTICO

Laboratorio 5: Construcción de un Dashboard con Streamlit / Plotly

Desarrollo de una Data App interactiva completa integrando predicciones de Churn y VoC

FICHA TÉCNICA DEL LABORATORIO

Objetivos y Stack Tecnológico

Diseñar y desplegar una aplicación web de analítica ejecutiva interactiva en Python puro.

- **Datos de Entrada:**
- Outputs combinados de los modelos predictivos y de NLP previos.
- **Stack Técnico:**
- Python 3.10+, Streamlit, Plotly Express, pandas.
- **Enfoque de Arquitectura:**
- Componentes reactivos desacoplados con caché en memoria (@st.cache_data).
- **Tiempo Asignado:**
- 60 minutos (45 min desarrollo guiado + 15 min demo interactiva).

HITOS DE CONSTRUCCIÓN EN STREAMLIT

Módulos de la Aplicación

Estructura modular del script que cada alumno implementará:

- 1. Configuración de página responsive y paleta corporativa coherente.
- 2. Construcción de filtros dinámicos en barra lateral.
- 3. Renderizado de la fila de KPIs estratégicos con formato condicional.
- 4. Scatter plot interactivo de clientes con tooltips enriquecidos.
- 5. Distribución de polaridad de sentimiento por categoría de producto.
- 6. Tabla de auditoría con botón de exportación para el equipo comercial.

MÓDULO 6 • 1.5 HORAS LECTIVAS

Casos Prácticos, Proyectos y Cierre

De la Experimentación a la Operación Real: Arquitecturas End-to-End, MLOps, Ética y Proyecto Integrador

CONTENIDOS TÉCNICOS

- Arquitectura de referencia industrial para soluciones predictivas y cognitivas.
- Estudio de caso de éxito: hiperpersonalización y retención 360° con ROI demostrado.
- MLOps en producción: monitorización de Data Drift, Concept Drift y gobernanza ética (EU AI Act).
- Metodología y rúbrica de evaluación para el Proyecto Final Integrador.
- Conclusiones del programa, hoja de ruta del profesional y turno de debate.

LABORATORIO PRÁCTICO & RESULTADO

- **Práctica: Proyecto Final Integrador Transversal**
- Objetivo: Resolución end-to-end de un caso de negocio aplicando los 5 módulos formativos.
- Entregable: Repositorio de código completo, pipeline reproducible y presentación ejecutiva.

MÓDULO 6 • ARQUITECTURA INTEGRAL

Arquitectura Industrial End-to-End de Analítica e Inteligencia Cognitiva

Blueprint tecnológico completo: desde la ingesta heterogénea hasta la acción automatizada

CAPA 1 • INGESTA

DataOps & Lakehouse

Captura y gobierno de datos heterogéneos.

- Streaming: Kafka / Event Hubs para telemetría.
- Batch: Airflow + dbt para transacciones ERP/CRM.
- Lakehouse ACID: Delta Lake / Apache Iceberg.
- Catálogo de datos unificado y linaje.

CAPA 2 • MLOPS

Plataforma de Modelado

Entrenamiento, tracking y versionado.

- Feature Store sincronizado (Online/Offline).
- Experiment Tracking con MLflow / Weights&Biases.
- Pipelines de CI/CD para reentrenamiento continuo.
- Registro de modelos con firmas y metadatos.

CAPA 3 • INFERENCIA

Serving & Servicios

Inferencia predictiva y cognitiva escalable.

- Microservicios de baja latencia con FastAPI / Triton.
- APIs cognitivas y LLMs orquestados con LangChain.
- Bases de datos vectoriales para RAG corporativo.
- Balanceo de carga y autoescalado en Kubernetes.

CAPA 4 • ACCIÓN

Consumo & Observabilidad

Decisión automatizada y auditoría.

- Dashboards ejecutivos en Streamlit / Power BI.
- Disparo de webhooks hacia CRM (Next Best Action).
- Monitorización de Data Drift con Evidently AI.
- Auditoría continua de explicabilidad SHAP.

PARIDAD ENTRE ENTRENAMIENTO Y SERVICIO (TRAINING-SERVING SKEW)

El mayor motivo de fallo de modelos en producción es la divergencia entre cómo se calcularon las variables durante la fase de ciencia de datos y cómo se calculan en la API en tiempo real. La adopción de un Feature Store centralizado garantiza que la misma definición matemática de variable (código reutilizado) sirva tanto al entrenamiento sobre terabytes de datos históricos como a la inferencia sobre un único evento HTTP en milisegundos.

Caso de Éxito: Hiperpersonalización y Retención de Clientes 360°

Implementación integral en una multinacional de servicios con métricas de retorno cuantificadas

1 • EL DESAFÍO DE NEGOCIO

Pérdida de Cartera y Quejas

Compañía de telecomunicaciones con 3M de clientes y fuga acelerada.

- **Tasa de Churn Mensual:**
- 3.2% sostenido (pérdida anual de ~115.000 clientes).
- **Saturación Operativa:**
- Incremento del 40% en quejas de clientes en soporte técnico.
- **Falta de Contexto:**
- Ofertas de retención genéricas que molestaban al usuario enfadado.
- **Coste Financiero:**
- Impacto negativo estimado en 18M€ anuales de facturación.

2 • LA SOLUCIÓN COGNITIVA

Arquitectura Integrada

Fusión de analítica avanzada predictiva con procesamiento cognitivo.

- **Modelo XGBoost de Churn:**
- Scoring probabilístico diario de la cartera con PR-AUC de 0.88.
- **Análisis VoC en Streaming:**
- Clasificación de polaridad y emociones en transcripciones de voz.
- **Next Best Action (NBA):**
- Motor de decisión prescriptivo con políticas personalizadas.
- **Dashboard Operativo:**
- Interfaz Streamlit conectada al CRM de los teleoperadores.

3 • IMPACTO Y RETORNO (ROI)

Resultados Cuantificados

Retorno de inversión demostrado en los primeros 12 meses de operación.

- **Reducción Neta de Churn:**
- Bajada del 3.2% al 2.4% (ahorro directo de 4.2M€ anuales).
- **Conversión de Campañas:**
- Incremento del 11% al 28% en la aceptación de promociones.
- **Eficiencia en Soporte:**
- Reducción del 35% en el tiempo medio de atención por ticket.
- **Payback del Proyecto:**
- Recuperación total de la inversión en tecnología en solo 4.5 meses.

MLOps, Monitorización de Deriva (Drift) y Gobernanza Ética

Asegurando la estabilidad operativa y el cumplimiento del marco legal europeo (EU AI Act)

DEGRADACIÓN 1 • ENTRADA

Data Drift (Deriva de Datos)

Variación en la distribución marginal de las variables $P(X)$ sin cambio en la etiqueta.

- **Causa Habitual:**
- Cambios estacionales, aperturas a nuevos mercados o cambios de comportamiento social.
- **Métricas de Detección:**
- Test Kolmogorov-Smirnov (KS), Divergencia KL, Population Stability Index (PSI > 0.25 alerta roja).
- **Solución Operativa:**
- Reentrenamiento automatizado con ventanas temporales móviles recientes.

DEGRADACIÓN 2 • RELACIÓN

Concept Drift (Deriva de Concepto)

Transformación de la relación estadística entre variables y objetivo $P(y|X)$.

- **Causa Habitual:**
- Nuevos patrones de fraude, crisis macroeconómicas, cambios en la competencia.
- **Impacto Inmediato:**
- Caída en picado del AUC o F1-score aunque los datos de entrada parezcan normales.
- **Solución Operativa:**
- Modelos adaptativos online, detección de puntos de cambio y re-calibración de umbrales.

GOBERNANZA • LEGAL Y ÉTICA

Marco Regulatorio (EU AI Act)

Auditoría ética, transparencia y cumplimiento normativo estricto.

- **Clasificación por Riesgo:**
- Sistemas de alto riesgo (scoring crediticio, RRHH, salud) exigen supervisión humana obligatoria.
- **Derecho a Explicación (GDPR):**
- Justificación matemática de decisiones denegatorias mediante valores SHAP auditables.
- **Control de Sesgos Discriminatorios:**
- Auditorías de disparidad de impacto por género, edad u origen.

Proyecto Final Integrador: Guía de Implementación y Rúbrica

Consolidación transversal de los 5 laboratorios en un caso empresarial aplicable

ESTRUCTURA DEL PROYECTO

Las 5 Fases del Proyecto Integrador

Flujo de trabajo para resolver un caso de negocio transversal de extremo a extremo:

- **Fase 1 • DataOps & EDA:**
- Auditoría estadística, imputación y feature engineering en pipelines scikit-learn.
- **Fase 2 • Modelado Predictivo:**
- Entrenamiento de XGBoost, tuning con Optuna y fijación de umbral por costes.
- **Fase 3 • Inteligencia Cognitiva:**
- Análisis de sentimiento con Hugging Face y extracción de tópicos de clientes.
- **Fase 4 • Visualización:**
- Construcción de dashboard interactivo en Streamlit con explicabilidad SHAP.
- **Fase 5 • Defensa Ejecutiva:**
- Presentación oral de 10 minutos orientada al impacto económico y plan de MLOps.

RÚBRICA DE CALIFICACIÓN OFICIAL

Criterios de Evaluación y Ponderación

Parámetros objetivos para la superación del programa formativo:

- **30% • Rigor Metodológico y Métricas:**
- Ausencia total de data leakage, validación cruzada correcta y justificación de métricas.
- **25% • Arquitectura y Calidad de Código:**
- Modularidad, reproducibilidad en notebooks, gestión de dependencias y limpieza.
- **25% • Dashboard y Percepción Visual:**
- Diseño intuitivo, cumplimiento del ratio datos-tinta y fluidez interactiva.
- **20% • Orientación al Negocio y Storytelling:**
- Capacidad de traducir hallazgos técnicos en planes de acción y retorno de inversión.

PROGRAMA FORMATIVO EJECUTIVO • 15 HORAS

Conclusiones y Hoja de Ruta del Profesional en IA y Analítica

De la Capacitación Técnica a la Transformación Organizacional Sostenible

El Dato como Activo

La analítica solo genera valor cuando está alineada con decisiones críticas y cuantificables.

Sinergia Cuántica

La combinación de modelos predictivos y capacidades cognitivas es la ventaja competitiva definitiva.

Rigor y Ética

El éxito duradero exige gobernanza continua, observabilidad de MLOps y transparencia explicable.

Documentación del Docente y Guía de Laboratorios • Formato Panorámico 16:9 • Español Técnico