PROGRAMA FORMATIVO EJECUTIVO · 15 HORAS

Analítica Avanzada e Inteligencia Cognitiva

De los Datos a la Decisión Automatizada: Machine Learning, NLP y Dashboards Estratégicos



ENCUADRE PEDAGÓGICO

Objetivos Oficiales y Competencias a Desarrollar

Modelado Predictivo & ML

- **Modelos avanzados:** Regresión, ensembles (XGBoost) y clusterización.
- **Preprocesamiento:** Imputación, escalado e ingeniería de variables.
- **Validación robusta:** Estratificación temporal, ROC/PR y matriz de confusión.
- **Explicabilidad:** Interpretación de caja negra mediante valores SHAP.

Inteligencia Cognitiva & NLP

- **Procesamiento:** Tokenización, limpieza y lematización multicapa.
- **Espacios densos:** Embeddings y Transformers preentrenados.
- **Minería de opinión:** Análisis de sentimiento y Voice of Customer (VoC).
- **Arquitectura RAG:** Recuperación semántica y generación asistida.

Visualización & Storytelling

- **Gramática visual:** Principios perceptivos Gestalt para paneles analíticos.
- **Dashboards ágiles:** Cuadros de mando interactivos con Streamlit.
- **Gestión del riesgo:** Incertidumbre, intervalos de confianza y alertas.
- **Impacto ejecutivo:** Traducción de métricas a euros de negocio.

COMPROMISO FORMATIVO: Al concluir las 15 horas lectivas, cada participante dispondrá de un repositorio funcional con 5 laboratorios prácticos en Python y un proyecto transversal integrador listo para su adaptación corporativa.

ORGANIZACIÓN DEL CURSO

Estructura Modular y Cronograma del Curso (15 h)

Módulo	Denominación Temática	Enfoque Técnico	Laboratorio Práctico Incluido	Duración
Módulo 1	Introducción a la Analítica Avanzada	Madurez analítica, ciclo CRISP-DM y Lakehouse moderno	Lab 1: Profilado y Calidad de Datos (EDA)	2.5 h
Módulo 2	Fundamentos de Inteligencia Cognitiva	Sistemas cognitivos, APIs multimodales, Embeddings y RAG	Lab 2: Extracción Semántica y Embeddings	2.5 h
Módulo 3	Modelos Predictivos y Machine Learning	Supervisado/No supervisado, XGBoost, Validación y SHAP	Lab 3: Modelo Predictivo de Churn con XAI	3.5 h
Módulo 4	Análisis de Sentimientos y NLP	Preprocesamiento, Transformers, Voice of Customer	Lab 4: Pipeline de Sentimiento con Hugging Face	2.5 h
Módulo 5	Visualización de Datos Avanzada	Percepción Gestalt, Storytelling y Dashboards Streamlit	Lab 5: Cuadro de Mando Interactivo con KPIs	2.0 h
Módulo 6	Casos Prácticos, MLOps y Proyecto	Arquitectura E2E, Monitorización de Drift y Ética IA	Proyecto Final Integrador Transversal	1.5 h

01

MÓDULO 1 · 2.5 HORAS LECTIVAS

Introducción a la Analítica Avanzada

Conceptos Clave, Continuo de Madurez y Ciclo de Vida de Proyectos de Datos

- De los datos a la decisión: continuo de madurez analítica
- Diferencias entre analítica descriptiva, predictiva y prescriptiva
- El ciclo metodológico de proyectos: CRISP-DM y TDSP
- Arquitecturas modernas: Lakehouse, Delta y Feature Stores
- Laboratorio 1: Profilado y auditoría de calidad de datos

MADUREZ ANALÍTICA

El Continuo de Madurez Analítica (Gartner Framework)

1

01 · Descriptiva

¿Qué ha ocurrido?

- Enfoque retrospectivo
- Herramientas: SQL, BI, KPIs
- Informes estáticos y cuadros de mando

2

02 · Diagnóstica

¿Por qué ocurrió?

- Análisis causal y drill-down
- Minería de datos y correlaciones
- Identificación de causas raíz

3

03 · Predictiva

¿Qué ocurrirá?

- Estimación probabilística
- Machine Learning y series temporales
- Scoring y alertas preventivas

4

04 · Prescriptiva

¿Qué debemos hacer?

- Decisión y optimización
- Programación matemática y reglas
- Acción autónoma automatizada

TRANSICIÓN CLAVE: Avanzar hacia la derecha del continuo multiplica el retorno económico, pero exige mayor rigor en la calidad del dato en tiempo real, gobierno de modelos y tolerancia al riesgo algorítmico.

ANÁLISIS COMPARATIVO

Matriz Comparativa de Enfoques Analíticos

Nivel Analítico	Horizonte	Herramientas Clave	Caso Práctico (Retail / Salud)	Impacto en el Negocio
Descriptiva	Pasado (T-n)	SQL, Power BI, Dashboards OLAP	Informe de ventas por SKU o reingresos de pacientes en el mes.	Visibilidad retrospectiva del negocio.
Diagnóstica	Pasado reciente	Python (pandas, scipy), Análisis causal	Detección de roturas de stock o causa de reingreso ambulatorio.	Comprensión de causas raíz y fallos.
Predictiva	Futuro (T+1)	Scikit-learn, XGBoost, Prophet	Previsión de demanda a 14 días o scoring de riesgo de fuga/churn.	Reducción de inventario ocioso y pérdida.
Prescriptiva	Futuro accionable	Optimización (Gurobi, PuLP), Heurísticas	Reaprovisionamiento y pricing dinámico o teleconsulta médica.	Maximización de márgenes y automatización.

METODOLOGÍA DE PROYECTOS

Ciclo de Vida de Proyectos de Datos: De CRISP-DM a TDSP

01 · Negocio

- **Objetivo:** Traducir la necesidad en métricas analíticas.
- **Entregable:** KPIs, límites de coste y diseño de caso.

02 · Comprensión

- **Exploración:** Auditoría de calidad y patrones con EDA.
- **Detección:** Nulos, outliers y desbalanceo de clases.

03 · Preparación

- **Ingeniería:** Limpieza, imputación y codificación.
- **Partición:** División rigurosa train / val / test.

04 · Modelado

- **Algoritmos:** Entrenamiento de modelos supervisados.
- **Ajuste:** Validación cruzada y tuning fino.

05 · Evaluación

- **Negocio:** Validación de impacto económico y XAI.
- **Decisión:** Aprobación o retroceso a fases previas.

06 · Despliegue

- **Puesta en marcha:** APIs en tiempo real o por lotes.
- **MLOps:** Monitorización de drift y reentrenamiento.

Arquitectura Moderna de Datos: El Paradigma Lakehouse

Capa Bronce (Raw)

- **Ingesta pura:** Aterrizaje raw sin transformar desde ERP, CRM, IoT o APIs.
- **Formatos:** JSON, Parquet, CSV, audio y texto libre.
- **Trazabilidad:** Historial inmutable de auditoría completa.

Capa Plata (Curada)

- **Calidad:** Esquemas validados, deduplicación y tipado.
- **Gobernanza:** Transacciones ACID con Delta Lake e Iceberg.
- **Consumo:** Base limpia para analítica y exploración ML.

Capa Oro (Negocio)

- **Modelos:** Tablas dimensionales para reporting ejecutivo.
- **Feature Store:** Variables precomputadas de baja latencia.
- **Inferencia:** Servicio dual sincronizado offline/ online.

FEATURE STORE CORPORATIVO: Elimina el Training-Serving Skew al garantizar que variables como "gasto medio a 30 días" se calculen con idéntica lógica en Parquet masivo (offline) y en almacenes clave-valor tipo Redis (online en milisegundos).

Lab 1: Diagnóstico y Auditoría de Datos Empresariales

Ficha Técnica del Laboratorio

- **Dataset:** 50.000 registros transaccionales con 25 variables heterogéneas.
- **Stack técnico:** Python 3.10+, pandas, ydata-profiling, statsmodels, seaborn.
- **Duración:** 45 minutos (30 min trabajo guiado + 15 min puesta en común).
- **Hito clave:** Diagnóstico crítico previo a cualquier fase de modelado.

Protocolo de Ejecución en Notebook

- **Paso 1 · Profiling:** Generación de reporte global con distribuciones y alertas.
- **Paso 2 · Nulos:** Clasificación de patrones e imputación condicionada.
- **Paso 3 · VIF:** Filtrado de multicolinealidad en variables redundantes.
- **Paso 4 · Outliers:** Detección multivariante con Isolation Forest.
- **Paso 5 · Salida:** Exportación a formato Parquet con esquema tipado.

02

MÓDULO 2 · 2.5 HORAS LECTIVAS

Fundamentos de la Inteligencia Cognitiva

Sistemas Capaces de Percibir, Comprender Contexto, Razonar e Interactuar

- Los 4 pilares: comprensión, razonamiento, aprendizaje e interacción
- Evolución técnica: de sistemas expertos a modelos fundacionales
- Catálogo de APIs cognitivas cloud: visión, lenguaje, voz y decisión
- Arquitecturas empresariales RAG y bases de datos vectoriales
- Laboratorio 2: Extracción semántica y embeddings contextuales

¿Qué es la Inteligencia Cognitiva? Los 4 Pilares



Comprensión Multimodal

- **Percepción:** Valor en texto, audio, imágenes y vídeo.
- **Semántica:** Reconocimiento de intenciones y relaciones.
- **Precisión:** Resolución de ambigüedad y polisemia.



Razonamiento e Inferencia

- **Inferencia:** Razonamiento sobre grafos y vectores.
- **Evidencias:** Decisiones ante información incompleta.
- **Trazabilidad:** Explicación del camino deductivo.



Aprendizaje Continuo

- **Adaptación:** Ajuste continuo a nuevos datos.
- **Feedback:** Refinamiento con criterio humano experto.
- **Evolución:** Actualización sin olvido catastrófico.



Interacción en Lenguaje Natural

- **Diálogo:** Conversaciones multietapa con contexto.
- **Tono:** Generación adaptada a directivos o técnicos.
- **Copilotos:** Colaboración fluida persona-algoritmo.

EVOLUCIÓN TECNOLÓGICA

De las Reglas Simbólicas a los Modelos Fundacionales

1

1 · Reglas (1980)

Sistemas Expertos

- Reglas Si/Entonces
- Alta interpretabilidad
- Frágiles ante excepciones
- Sin aprendizaje adaptativo

2

2 · ML Estadístico

Scikit-learn, SVM, RF

- Métricas cuantitativas
- Fuerte en datos tabulares
- Dependencia absoluta de feature engineering manual

3

3 · Deep Learning

CNNs, LSTMs, GRUs

- Representación interna
- Visión y secuencias
- Alto consumo de GPU
- Gradiente desvanecido en texto

4

4 · Transformers

Modelos Fundacionales

- Autoatención paralela
- Comprensión contextual
- Capacidades zero-shot
- Base de los LLMs modernos

MECANISMO DE AUTOATENCIÓN (SELF-ATTENTION): A diferencia de las arquitecturas secuenciales que leían palabra a palabra perdiendo memoria en textos largos, la autoatención calcula la afinidad semántica simultánea entre todos los tokens mediante matrices de Query, Key y Value: Attention(Q,K,V) = softmax((Q·K^T) / √d_k) · V.

SERVICIOS CLOUD

Catálogo de Servicios y APIs Cognitivas Empresariales



Visión Artificial

- **OCR analítico:** Extracción de tablas y texto en documentos.
- **Detección:** Reconocimiento de objetos y anomalías en streaming.
- **Proveedores:** Azure Vision, AWS Rekognition, Google Vision.



Lenguaje y Texto

- **Sentimiento:** Análisis de polaridad y Voice of Customer.
- **Entidades:** Extracción de NER y anonimización de PII.
- **Proveedores:** Azure AI Language, AWS Comprehend, Vertex NLP.



Voz y Audio

- **STT / TTS:** Transcripción precisa y síntesis neuronal.
- **Biometría:** Identificación de locutor en centros de llamadas.
- **Proveedores:** Azure Speech, AWS Transcribe/Polly, Google Speech.



Búsqueda y Decisión

- **Búsqueda vectorial:** Recuperación híbrida por relevancia semántica.
- **Detección:** Anti-fraude y scoring de riesgo en tiempo real.
- **Proveedores:** Azure AI Search, AWS Kendra, Vertex Search.

Arquitectura RAG Empresarial: De los Datos al LLM

1

1 · Ingesta & Chunking

Partición de Documentos

- Extracción de PDFs, wikis, ERP
- Chunks de 400-500 tokens
- Solapamiento (overlap) de 50 tokens para no romper frases

2

2 · Vectorización

Modelos de Embeddings

- Conversión de texto a vectores densos (384 / 1536 dim)
- Almacenamiento indexado en Vector DB (Chroma, Pinecone)

3

3 · Búsqueda K-NN

Recuperación Semántica

- Vectorización de la consulta
- Cálculo de similitud coseno
- Filtrado por metadatos y permisos corporativos de acceso

4

4 · Generación

Respuesta Fundamentada

- Inyección de contexto al LLM
- Respuestas auditables sin alucinaciones
- Cita rigurosa de fuentes internas

BÚSQUEDA HÍBRIDA INDUSTRIAL (HYBRID SEARCH): En producción se combina la búsqueda vectorial (similitud semántica de ideas) con búsqueda léxica BM25 (coincidencia exacta de códigos o números de contrato) y un re-ranking intermedio para garantizar la máxima precisión documental.

Lab 2: Extracción Semántica y Embeddings con ChromaDB

Ficha Técnica del Laboratorio

- **Corpus:** 200 políticas de empresa y cláusulas contractuales.
- **Librerías:** Python 3.10+, ChromaDB, sentence-transformers, LangChain.
- **Modelo:** all-MiniLM-L6-v2 (384 dimensiones, eficiente y local).
- **Duración:** 45 minutos (30 min desarrollo + 15 min debate técnico).

Hitos del Pipeline de Código

- **Hito 1 · Chunking:** Partición con solapamiento semántico de 50 tokens.
- **Hito 2 · Vectorización:** Generación de matrices densas de embeddings.
- **Hito 3 · Almacén:** Persistencia e indexación de metadatos en ChromaDB.
- **Hito 4 · Recuperación:** Búsqueda semántica K-NN por proximidad coseno.
- **Hito 5 · Grounding:** Construcción del prompt libre de alucinaciones.

03

MÓDULO 3 · 3.5 HORAS LECTIVAS

Modelos Predictivos y Machine Learning

De la Teoría Estadística a los Algoritmos de Producción: Supervisado, No Supervisado y Validación

- Taxonomía matemática y conceptual del Machine Learning
- Algoritmos supervisados: lineales, regularización y ensembles (XGBoost)
- Aprendizaje no supervisado: clustering (K-Means) y reducción (PCA)
- Feature engineering, prevención de data leakage y validación cruzada
- Métricas de evaluación, matriz de costes y explicabilidad con SHAP
- Laboratorio 3: Modelo predictivo de Churn con XGBoost y XAI

Taxonomía del Machine Learning: 3 Paradigmas

Aprendizaje Supervisado

- **Regresión:** Previsión de variables continuas (demanda, precios, LTV).
- **Clasificación:** Categorías discretas (abandono, detección de fraude).
- **Algoritmos:** Regresión Logística, Random Forest, XGBoost, LightGBM.
- **Reto clave:** Coste del etiquetado y prevención de sobreajuste.

Aprendizaje No Supervisado

- **Clustering:** Segmentación de clientes sin categorías preestablecidas.
- **Reducción:** Compresión del espacio preservando varianza (PCA).
- **Anomalías:** Aislamiento de casos atípicos (Isolation Forest).
- **Reto clave:** Evaluación objetiva sin una etiqueta de verdad base.

Aprendizaje por Refuerzo

- **Bucle interactivo:** Estado (S), Acción (A) y Recompensa (R).
- **Aplicaciones:** Pricing dinámico, logística y gestión de inventario.
- **Algoritmos:** Q-Learning, DQN, PPO, modelos Actor-Critic.
- **Reto clave:** Requiere entornos de simulación de alta fidelidad.

Modelos Supervisados: De Modelos Lineales a Boosting

Modelos Lineales & Regularización

- **Interpretabilidad:** Relación aditiva $y = \beta_0 + \sum \beta_j X_j$.
- **Ridge (L2):** Penalización cuadrática ante varianza.
- **Lasso (L1):** Selección de variables forzando pesos a 0.

Random Forest (Bagging Paralelo)

- **Bootstrap:** Muestreo aleatorio de filas con reemplazo.
- **Variables:** Subconjunto aleatorio en división de nodo.
- **Robustez:** Promedio de árboles que reduce la varianza.

XGBoost & LightGBM (Boosting)

- **Secuencial:** Cada árbol minimiza el error acumulado.
- **Segundo orden:** Optimización de gradiente y hessiano.
- **Producción:** Rendimiento estado del arte en datos tabulares.

SVM & Redes Neuronales (MLP)

- **Kernel Trick:** Proyección RBF a dimensiones superiores.
- **Perceptrón:** Capas densas con activación no lineal.
- **Casos clave:** Interacciones no lineales de alta escala.

NO SUPERVISADO

Clustering y Reducción de Dimensionalidad

Algoritmos de Clustering

- **K-Means:** Partición por centroides. Escalable, sensible a escala de variables.
- **DBSCAN:** Agrupamiento por densidad espacial; aísla ruido y outliers nativamente.
- **Jerárquico:** Construcción de dendrogramas para taxonomías de negocio.
- **Evaluación:** Coeficiente Silhouette (-1 a +1) e índice Davies-Bouldin.

Compresión & Reducción (PCA)

- **PCA:** Transformación lineal que maximiza la varianza acumulada retenida.
- **Varianza:** Selección de componentes que retengan al menos el 80-90% de señal.
- **t-SNE / UMAP:** Mapeo no lineal para proyección visual exploratoria en 2D y 3D.
- **Producción:** Eliminación previa de multicolinealidad antes de modelos supervisados.

FEATURE ENGINEERING

Ingeniería de Variables y Prevención de Data Leakage

1

1 · Imputación

Valores Ausentes

- Mediana o moda por grupo
- KNN Imputer multivariante
- Variable bandera de missing

2

2 · Codificación

Variables Categóricas

- One-Hot (baja cardinalidad)
- Target Encoding regularizado
- Weight of Evidence (WoE)

3

3 · Escalado

Magnitudes Numéricas

- StandardScaler (z-score)
- RobustScaler (con outliers)
- Transformación Logarítmica

4

4 · Negocio

Ratios e Interacción

- Métricas temporales (T-7 / T-30)
- Recencia, Frecuencia, Valor
- Ratios de aceleración

PREVENCIÓN ABSOLUTA DE DATA LEAKAGE: Cualquier cálculo estadístico (medias, varianzas, imputadores o vocabularios) debe entrenarse EXCLUSIVAMENTE sobre Train y aplicarse a ciegas sobre Validación y Test mediante pipelines reproducibles (scikit-learn Pipeline). De lo contrario, las métricas serán falsamente optimistas.

Evaluación de Clasificación y Matriz de Costes

Precisión

- **Fórmula:** TP / (TP + FP)
- **Objetivo:** Minimizar Falsos Positivos.
- **Foco:** Evitar alarmas erróneas de coste alto.

Sensibilidad

- **Fórmula:** TP / (TP + FN)
- **Objetivo:** Minimizar Falsos Negativos.
- **Foco:** Capturar toda fuga o fraude crítico.

F1-Score

- **Fórmula:** 2·(P·R) / (P + R)
- **Objetivo:** Equilibrio armónico.
- **Foco:** Métrica única balanceada.

PR-AUC

- **Fórmula:** Área bajo curva PR
- **Objetivo:** Capacidad de ranking.
- **Foco:** Clave ante desbalanceo extremo.

Matriz de Confusión	Predicción: No Abandono (0)	Predicción: Abandono (1)	Impacto Económico del Error
Real: Fiel (0)	Verdadero Negativo (TN) Cliente satisfecho preservado	Falso Positivo (FP - Error Tipo I) Oferta enviada innecesariamente	Coste de campaña innecesaria (ej. 20 € de descuento).
Real: Fuga (1)	Falso Negativo (FN - Error Tipo II) Cliente que se marcha sin aviso	Verdadero Positivo (TP) Cliente retenido proactivamente	Pérdida del valor vitalicio del cliente (LTV = 500 €).

Validación Cruzada y Trade-off Sesgo-Varianza

Dilema Sesgo-Varianza

- **Subajuste (Alto Sesgo):** Modelo excesivamente simplificado. Error alto en train y en test.
- **Sobreajuste (Alta Varianza):** Memorización del ruido muestral. Error mínimo en train, pésimo en test.
- **Mitigación:** Aumentar observaciones, regularización L1/L2, podar árboles (max_depth).
- **Punto óptimo:** Complejidad calibrada que minimiza el error de generalización.

Estrategias de Partición

- **Train / Val / Test:** Partición 60/20/20 con cofre sellado de test final para auditoría.
- **Stratified K-Fold:** K pliegues preservando exactamente el porcentaje de clase minoritaria.
- **TimeSeriesSplit:** Validación temporal progresiva; prohibido mezclar futuro con pasado.
- **Nested CV:** Ajuste de hiperparámetros anidado para evitar sesgo de optimismo.

Lab 3: Predicción de Churn con XGBoost y SHAP (XAI)

Especificaciones del Modelo

- **Caso de Negocio:** Predicción de abandono mensual en cartera B2B.
- **Algoritmo:** XGBoost con optimización bayesiana (Optuna).
- **Métrica Clave:** PR-AUC y minimización de coste total de churn.
- **Stack:** scikit-learn, xgboost, optuna, shap, matplotlib.

Hitos del Laboratorio

- **Hito 1 · Pipeline:** Preprocesamiento hermético sin fugas de datos.
- **Hito 2 · Tuning:** Calibración de learning_rate, depth y subsample.
- **Hito 3 · Costes:** Selección de punto de corte óptimo por ROI.
- **Hito 4 · SHAP:** Extracción de valores Shapley para interpretabilidad.
- **Hito 5 · Informe:** Traducción de conclusiones a recomendaciones comerciales.

04

MÓDULO 4 · 2.5 HORAS LECTIVAS

Análisis de Sentimientos y NLP

Desbloqueando el Valor del Texto: De la Sintaxis a la Semántica Contextual de los Transformers

- El pipeline de preprocesamiento en NLP: tokenización y normalización
- Representaciones vectoriales: BoW, TF-IDF, Word2Vec y Transformers
- Técnicas de análisis de sentimiento: léxicos, clasificadores y LLMs
- Aspect-Based Sentiment Analysis (ABSA) y minería de opiniones VoC
- Laboratorio 4: Clasificación de sentimiento con Hugging Face

PREPROCESAMIENTO TEXTUAL

Pipeline de Preprocesamiento en Lenguaje Natural

1

1 · Normalización

Limpieza de Texto

- Eliminación de etiquetas HTML
- Mapeo semántico de emojis
- Homogeneización de minúsculas y caracteres de escape

2

2 · Tokenización

Subword Tokenization

- Segmentación por subpalabras
- Algoritmos BPE y WordPiece
- Manejo total de palabras desconocidas (cero errores OOV)

3

3 · Morfología

Lematización vs Stemming

- Stemming: corte heurístico de afijos
- Lematización: reducción al lema formal según categoría gramatical

4

4 · Secuencias

Alineación Numérica

- Preservación de negaciones
- Truncation y Padding uniforme
- Generación de máscaras de atención para el modelo

EL DILEMA DE LAS STOPWORDS: En modelos estadísticos clásicos (TF-IDF), suprimir stopwords evita inflar la dimensionalidad. Pero en Transformers, conservarlas es vital: la autoatención las utiliza para capturar la estructura gramatical y la polaridad invertida en negaciones ("no está mal" frente a "está mal").

Representación Vectorial: De BoW a Embeddings

Vectores Dispersos (TF-IDF)

- **Mecánica:** Matriz de frecuencias ponderada por especificidad en el corpus.
- **Ventajas:** Computacionalmente ligero, rápido de ajustar e interpretable.
- **Límite severo:** Ortogonalidad estricta: ignora sinónimos y destruye el orden.

Embeddings Estáticos (Word2Vec)

- **Mecánica:** Vectores densos (300 dim) aprendidos por coocurrencia local.
- **Ventajas:** Geometría semántica: captura analogías y cercanías de significado.
- **Límite severo:** Vectores estáticos: no puede distinguir sentidos en polisemia.

Atención Contextual (Transformers)

- **Mecánica:** Autoatención bidireccional sobre la frase completa (BERT, RoBERTa).
- **Ventajas:** Representación dinámica dependiente del contexto circundante.
- **Requisito:** Mayor coste de GPU/CPU en inferencia (optimizable con ONNX).

Técnicas de Análisis de Sentimientos y Minería VoC

Diccionarios Léxicos

- **Mecánica:** Puntuaciones fijas por término con reglas para negaciones.
- **Ventajas:** Sin entrenamiento ni datos etiquetados previos.
- **Limitación:** Incapaz de capturar sarcasmo o jerga especializada.

Supervisado Clásico

- **Mecánica:** TF-IDF con n-gramas + Regresión Logística o SVM.
- **Ventajas:** Excelente relación entre precisión y coste en CPU.
- **Limitación:** Requiere miles de ejemplos etiquetados por humanos.

Transformers & LLMs

- **Mecánica:** Modelos contextuales preentrenados en español (BETO).
- **Ventajas:** Comprensión superior de matices, ironía y emociones.
- **Inferencia:** Zero-shot o fine-tuning sobre datasets corporativos.

VALOR ESTRATÉGICO DE ABSA (ASPECT-BASED SENTIMENT ANALYSIS): Saber que un cliente está "insatisfecho" es insuficiente. ABSA descompone el comentario en tuplas estructuradas [Entidad, Aspecto, Polaridad], por ejemplo: [Habitación: +0.9 (Amplia)], [Ubicación: +0.8 (Céntrica)], [Atención: -0.85 (Check-in lento)], permitiendo intervenciones operativas quirúrgicas.

CASOS DE NEGOCIO

Aplicaciones Empresariales: Voice of Customer y Retención

Monitorización de Marca en Streaming

- **Detección:** Alertas tempranas ante picos anómalos de quejas.
- **Clustering:** Agrupación semántica para aislar el foco de la crisis.
- **Impacto:** Respuesta del gabinete de prensa en menos de 15 minutos.

Triaje Inteligente de Soporte

- **Enrutamiento:** Clasificación automática por urgencia y departamento.
- **Resumen:** Extracción de puntos clave para agilizar la respuesta.
- **Impacto:** Reducción del 40% en tiempo medio de resolución (MTTR).

Inteligencia de Producto Competitiva

- **Benchmarking:** Minería de reseñas de productos de la competencia.
- **Detección:** Identificación de carencias ajenas para captación.
- **Impacto:** Priorización del roadmap de desarrollo con datos reales.

Prevención Activa en Call Centers

- **Voz a Texto:** Análisis de polaridad en streaming en llamada.
- **Copiloto:** Sugerencia de retención en pantalla del agente.
- **Impacto:** Rescate de un 22% de clientes en riesgo.

Lab 4: Clasificación de Sentimiento con Hugging Face

Ficha Técnica del Laboratorio

- **Corpus:** 10.000 opiniones de e-commerce en español con notas 1-5.
- **Librerías:** transformers, datasets, scikit-learn, BERTopic, pandas.
- **Modelos:** TF-IDF baseline vs RoBERTa preentrenado en español.
- **Duración:** 45 minutos (30 min desarrollo + 15 min análisis de error).

Hitos del Pipeline de NLP

- **Hito 1 · Limpieza:** Normalización de caracteres y preservación sintáctica.
- **Hito 2 · Baseline:** Ajuste del modelo lineal de referencia para control.
- **Hito 3 · Transformer:** Inferencia por lotes con pipeline de Hugging Face.
- **Hito 4 · Diagnóstico:** Análisis de matriz de confusión y falsos positivos.
- **Hito 5 · BERTopic:** Extracción de tópicos recurrentes en opiniones negativas.

05

MÓDULO 5 · 2.0 HORAS LECTIVAS

Visualización de Datos Avanzada

Comunicar con Impacto: Principios de Percepción, Arquitectura de Dashboards y Storytelling

- Fundamentos cognitivos: atributos preatentivos y leyes de Gestalt
- El ratio datos-tinta de Tufte y selección rigurosa de gráficos
- Ecosistema: BI corporativo (Power BI) vs Data Apps (Streamlit)
- Anatomía y diseño de dashboards ejecutivos para toma de decisiones
- Laboratorio 5: Dashboard interactivo con Streamlit y Plotly

Percepción Visual y Gramática de Gráficos

Atributos Preatentivos

- **Jerarquía visual:** Posición > Longitud > Área > Color > Ángulo.
- **Uso del color:** Exclusivamente para dirigir atención o alertar.
- **Sobriedad:** Máximo 2 atributos visuales combinados por elemento.

Psicología de la Gestalt

- **Proximidad:** Agrupar métricas afines y separar las no relacionadas.
- **Cerramiento:** Tarjetas con fondos suaves para delimitar contextos.
- **Continuidad:** Alinear filtros, cabeceras y ejes para guiar la vista.

Data-Ink Ratio (Tufte)

- **Cero Chartjunk:** Eliminar 3D artificial, degradados y sombras densas.
- **Cuadrículas:** Atenuadas en gris muy claro o suprimidas.
- **Etiquetado:** Directo sobre los datos evitando leyendas lejanas.

Ecosistema: Plataformas BI vs Data Apps en Código

Criterio de Evaluación	Plataformas de BI (Power BI / Tableau)	Data Apps en Código (Streamlit / Dash)
Audiencia Principal	Comités de dirección, analistas y mandos comerciales.	Científicos de datos, producto y usuarios técnicos.
Integración de ML / IA	Limitada a scripts integrados o inferencia batch previa.	Nativa: inferencia en tiempo real con scikit-learn y SHAP.
Gobernanza y RLS	Nativa empresarial (Azure AD / SSO y seguridad por fila).	Debe resolverse en código o en la capa del API gateway.
Curva de Desarrollo	Rápida en reportes estándar; compleja en interacciones.	Inmediata en Python puro (cero HTML, CSS o JS).
Simulación What-If	Limitada a parámetros DAX o selectores estáticos.	Dinámica total con sliders reactivos en milisegundos.

Anatomía y Arquitectura de un Dashboard Ejecutivo

ZONA 1 · BARRA DE CONTROL: Rango: Últimos 30 días • Segmento: B2B Enterprise • Región: Nacional • Pipeline actualizado hace 12 min

2.14%	+0.72	1.420	840 k€
TASA CHURN (▲ +0.3%)	SENTIMIENTO VoC (▲ +0.08)	CUENTAS EN RIESGO (>0.70)	VALOR EN RIESGO (ARR)

Zona 3 · Tendencia y Proyección con ML

- **Histórico consolidado:** Línea continua con datos reales de facturación.
- **Proyección XGBoost:** Línea discontinua con bandas de confianza al 95% a 60 días.
- **Puntos de inflexión:** Marcadores automáticos ante cambios de tarifa o campañas.

Zona 4 · Detalle Accionable Priorizado

- **Top Cuentas:** Listado ordenado por probabilidad de baja y valor LTV.
- **Micro-XAI:** Desglose de factores causales SHAP para cada cliente individual.
- **Acción:** Botón directo de asignación de oferta a gestores comerciales.

Integración de Modelos Predictivos y NLP en Paneles

Semántica Operativa

- **Categorización:** Mapeo de probabilidades en cuartiles de riesgo comercial.
- **Colores sobrios:** Formatos condicionales claros sin fatiga visual.
- **Impacto económico:** Estimación directa de pérdidas o ganancias asociadas.

Micro-XAI Embebida

- **Waterfall plot:** Gráfico de cascada al hacer clic sobre cualquier cliente.
- **Top 3 factores:** Variables que más empujan el score de predicción.
- **Confianza:** Apertura de la caja negra ante el usuario de operaciones.

Gobernanza y Calidad

- **Frescura:** Indicador explícito de la última ejecución batch del modelo.
- **Semáforo de Drift:** Aviso inmediato si los datos entrantes divergen de train.
- **Feedback:** Botón de reporte de falsos positivos por el gestor de cuentas.

BUCLE DE RETROALIMENTACIÓN HUMANA (HUMAN-IN-THE-LOOP): Un dashboard directivo no debe ser unidireccional. Incluir botones interactivos para validar o refutar alertas ("¿Considera acertada la predicción? Sí/No") permite enviar feedback directo a la capa Silver del Lakehouse para auditar sesgos y mejorar futuros reentrenamientos.

Lab 5: Construcción de un Dashboard con Streamlit



Ficha Técnica del Laboratorio

- **Entradas:** Datasets y predicciones consolidadas de los Labs 1, 3 y 4.
- **Stack:** Python 3.10+, Streamlit, Plotly Express, pandas.
- **Arquitectura:** Componentes reactivos con caché en memoria (@st.cache_data).
- **Duración:** 60 minutos (45 min desarrollo guiado + 15 min demo interactiva).



Hitos de Construcción de la Data App

- **Hito 1 · Layout:** Configuración responsive y sidebar de filtros dinámicos.
- **Hito 2 · KPIs:** Renderizado de scorecards ejecutivos con variación porcentual.
- **Hito 3 · Scatter:** Gráfico interactivo de riesgo cliente ponderado por LTV.
- **Hito 4 · VoC:** Distribución de sentimiento y quejas por categoría.
- **Hito 5 · Exportación:** Tabla de clientes prioritarios con descarga en CSV.

06

MÓDULO 6 · 1.5 HORAS LECTIVAS

Casos Prácticos, Proyectos y Cierre

De la Experimentación a la Operación Real: MLOps, Ética, Proyecto Integrador y Hoja de Ruta

- Arquitectura industrial de referencia para analítica e IA
- Caso de éxito: hiperpersonalización y retención 360° con ROI
- MLOps en producción: Data Drift, Concept Drift y EU AI Act
- Metodología y rúbrica oficial del Proyecto Final Integrador
- Conclusiones del programa, hoja de ruta y debate de cierre

ARQUITECTURA INTEGRAL

Arquitectura Industrial End-to-End de Analítica e IA

1

1 · DataOps / Ingesta

Lakehouse Unificado

- Streaming (Kafka / Event Hubs)
- Ingesta batch con dbt y Airflow
- Soporte ACID (Delta Lake / Iceberg)

2

2 · MLOps / Modelado

Plataforma ML

- Feature Store (Online/Offline)
- Tracking con MLflow y W&B
- Pipelines de CI/CD reproducibles

3

3 · Serving / Inferencia

Inferencia Híbrida

- Microservicios REST (FastAPI)
- Inferencia batch masiva periódica
- Orquestación RAG y Vector DB

4

4 · Acción / Vigilancia

Consumo y Gobierno

- Dashboards ejecutivos Streamlit
- Detección de drift (Evidently AI)
- Auditoría de explicabilidad SHAP

PARIDAD ENTRE ENTRENAMIENTO Y SERVICIO (TRAINING-SERVING PARITY): El fallo más común en producción es calcular variables de forma distinta en offline frente a la API online. La adopción de un Feature Store centralizado asegura que la misma lógica matemática sirva tanto al entrenamiento masivo como a la inferencia unitaria en milisegundos.

CASO DE ÉXITO REAL

Caso de Éxito: Retención 360° e Hiperpersonalización

1 · El Desafío de Negocio

- **Churn mensual:** 3.2% sostenido (fuga anual de ~115.000 clientes).
- **Quejas en soporte:** Incremento del 40% de reclamaciones críticas.
- **Falta de contexto:** Ofertas comerciales genéricas a usuarios molestos.
- **Coste económico:** Pérdida anual estimada en 18 M€ de ingresos.

2 · La Solución Integrada

- **Modelo XGBoost:** Scoring diario de probabilidad de baja con PR-AUC 0.88.
- **Análisis VoC:** Extracción de polaridad en llamadas y chats en directo.
- **Next Best Action:** Motor prescriptivo que selecciona la mejor oferta.
- **Data App:** Interfaz Streamlit para teleoperadores en call center.

3 · Impacto y Retorno (ROI)

- **Reducción de Churn:** Descenso al 2.4% (ahorro directo de 4.2 M€/año).
- **Conversión:** Subida del 11% al 28% en aceptación de promociones.
- **Eficiencia soporte:** Ahorro del 35% en tiempo de atención por caso.
- **Payback:** Retorno íntegro de la inversión técnica en 4.5 meses.

MLOps: Monitorización de Drift y Marco EU AI Act

Data Drift (Datos)

- **Definición:** Variación en la distribución marginal de entradas $P(X)$.
- **Causa habitual:** Cambios de mercado, estacionalidad o nuevas fuentes.
- **Detección:** Tests Kolmogorov-Smirnov y Population Stability Index (PSI).
- **Respuesta:** Reentrenamiento automático con ventanas recientes.

Concept Drift (Concepto)

- **Definición:** Mutación en la relación entre variables y objetivo $P(y|X)$.
- **Causa habitual:** Nuevos patrones de fraude o cambios de hábitos sociales.
- **Detección:** Caída súbita en AUC o F1-score con datos entrantes normales.
- **Respuesta:** Modelos adaptativos online y ajuste de umbrales de coste.

Marco Legal (EU AI Act)

- **Alto Riesgo:** Supervisión humana obligatoria en crédito, RRHH y salud.
- **Explicabilidad:** Derecho a justificación matemática comprensible (GDPR).
- **Auditoría de sesgos:** Control estricto de disparidad de impacto algorítmico.
- **Gobernanza:** Registro transparente de procedencia de datos y modelos.

Proyecto Final Integrador: Fases y Rúbrica Oficial

Las 5 Fases del Proyecto

- **Fase 1 · DataOps:** Auditoría estadística, imputación y feature engineering.
- **Fase 2 · Modelado:** XGBoost con tuning en Optuna y corte por costes.
- **Fase 3 · Cognitivo:** Análisis de sentimiento y extracción de tópicos con NLP.
- **Fase 4 · Dashboard:** Aplicación en Streamlit con explicabilidad XAI interactiva.
- **Fase 5 · Defensa:** Presentación ejecutiva de 10 minutos orientada al ROI.

Rúbrica de Calificación Oficial

- **30% · Rigor Metodológico:** Ausencia de data leakage y validación cruzada correcta.
- **25% · Calidad de Código:** Modularidad, reproducibilidad y limpieza en Python.
- **25% · Percepción Visual:** Diseño intuitivo, Tufte Data-Ink ratio y reactividad fluida.
- **20% · Negocio & Storytelling:** Traducción de conclusiones a impacto financiero demostrable.

Conclusiones y Hoja de Ruta del Profesional en Analítica e IA



El Dato como Activo

La analítica avanzada solo genera retorno sostenible cuando está alineada con decisiones operativas y métricas de impacto económico directo.



Sinergia Cuántica

La fusión de algoritmos predictivos estructurados con inteligencia cognitiva sobre texto no estructurado constituye la ventaja competitiva definitiva.



Rigor y Gobernanza

El éxito duradero en producción exige observabilidad continua mediante MLOps, prevención de deriva y explicabilidad transparente ante la sociedad.